Fitur Klasik pada Tiga Kasus Pengolahan Citra Digital: Kematangan Sawit, Penyakit Daun Padi, dan Retak Jalan

Radistha Kriska Dahana Purusa
NIM 561345
Pengolahan Citra Digital, Universitas Gadjah Mada
Email: radisthakriskadahanapurusa@mail.ugm.ac.id

Abstract—Laporan ini membandingkan tiga kasus pengolahan citra digital (PCD) berbasis fitur klasik: kematangan tandan buah segar (TBS) sawit, penyakit daun padi, dan retak jalan. Fitur warna (HSV, CIELab), tekstur (GLCM, LBP), bentuk, dan tepi diklasifikasikan dengan SVM RBF dan Random Forest di CPU. Validasi memakai k-lipat berstrata ($k = 5$, tiga pengacakan), scaler di dalam pipeline, dan pembagian per citra pada retak jalan. Macro-F1 terbaik adalah $0{,}858 \pm 0{,}062$ (sawit, tiga kelas, 150 citra), $0{,}858 \pm 0{,}079$ (padi, tiga kelas, 120 citra), dan $0{,}868 \pm 0{,}022$ (retak jalan, patch 64×64 dari 118 citra). Fitur yang cocok berbeda per kasus: warna (sawit), warna, bentuk, dan tekstur (padi), serta tepi dan morfologi garis (retak). Simpangan baku besar pada dua kasus pertama, sehingga selisih kecil tidak bermakna.

Index Terms—pengolahan citra digital, ekstraksi fitur, SVM, Random Forest, pertanian, inspeksi jalan

I. Pendahuluan

Pipeline PCD umumnya terdiri atas akuisisi, peningkatan mutu, segmentasi, ekstraksi fitur, dan pengenalan [1]. Pada masalah terapan, pemilihan fitur dan cara evaluasi sering lebih menentukan daripada pengklasifikasinya. Laporan ini menguji hal itu pada tiga kasus dengan data publik dan pengklasifikasi yang sama.

II. Tiga Kasus, Data, dan Fitur yang Cocok

Kasus 1: kematangan TBS sawit. Penilaian kematangan di pabrik masih banyak dilakukan secara visual dan mempengaruhi rendemen minyak; sistem visi warna untuk tugas ini sudah dikembangkan sejak lama [2] dan ditinjau oleh Lai et al. [3]. Data: Outdoor Tenera Oil Palm Fruit [4]. Dari 1,1 GB data, dipakai subset seimbang 150 citra (50 per kelas: unripe, ripe, overripe), diambil acak (seed 0) dari gabungan folder latih dan uji; kelas damaged dan empty dibuang karena terlalu sedikit. Fitur yang cocok adalah warna, karena pematangan mengubah pigmen eksokarp dari gelap ke merah-jingga: rata-rata, simpangan baku, dan skewness kanal HSV (hue dipetakan ke cos / sin) dan $L^*a^*b^*$ (21 fitur) pada piksel buah, ditambah tekstur GLCM dan LBP (14 fitur). Lihat juga [5].

Kasus 2: penyakit daun padi. Data: UCI Rice Leaf Diseases (120 citra, 3 kelas @40: bacterial leaf blight, brown spot, leaf smut). Penyakit dibedakan oleh warna, sebaran, dan bentuk bercak sehingga fitur yang dipakai berupa momen warna daun dan lesi (21+21), 7 deskriptor bentuk lesi (luas relatif, jumlah, eccentricity, solidity, extent, rasio sumbu), dan tekstur (14). Lesi diambil dengan ambang kanal a^* di dalam daun. Ekstraksi fitur untuk klasifikasi penyakit daun padi dibahas pada [6].

Kasus 3: retak jalan. Data: CrackForest [7] (118 citra 480×320 dengan anotasi piksel). Citra dipotong menjadi patch 64×64 tanpa tumpang tindih; patch berlabel retak bila memuat ≥ 30 piksel retak, patch dengan 1–29 piksel dibuang sebagai ambigu. Hasilnya 4.034 patch (1.235 retak, 2.799 non-retak). Retak adalah garis gelap tipis sehingga fitur yang cocok adalah tepi dan morfologi garis: Canny dan magnitudo Sobel, respons ridge Sato, panjang skeleton (9 fitur), ditambah tekstur GLCM/LBP (16 fitur). Pra-pengolahan: median dan CLAHE. Rujukan deteksi retak: [7], [8]. Tekstur: [9], [10]; warna: [11], [12].

III. Metode Eksperimen

Kode ada di exp/ (CPU; scikit-image, scikit-learn, OpenCV). Citra sawit diubah ke 256×256, padi ke sisi terpanjang 1024 piksel. Mask sawit memakai jarak Lab terhadap median tepi citra, Otsu, morfologi, dan komponen terbesar. Dua pengklasifikasi dipakai: SVM RBF ($C = 10, \gamma = \text{scale}$) dan Random Forest (200 pohon), keduanya class_weight=balanced dengan StandardScaler di dalam pipeline sehingga statistik hanya dihitung dari data latih tiap lipatan. Validasi: stratified 5-lipat untuk sawit dan padi; StratifiedGroupKFold dengan grup = citra untuk retak jalan, dan keterpisahan citra latih/uji diperiksa dengan assertion. Semua dijalankan untuk tiga seed (15 lipatan); dilaporkan macro-F1 rata-rata ± simpangan baku antar lipatan.

IV. Hasil

Pada sawit, warna saja (0,80) jauh lebih baik daripada tekstur saja (0,66), dan gabungan keduanya terbaik (0,858). Mask tidak memberi perbaikan yang jelas pada SVM (0,799 vs. 0,804). Galat terbanyak ada antar kelas berdekatan (SVM, akumulasi 3 seed: 21 ripe diprediksi unripe, 17 overripe diprediksi ripe). Pada padi, gabungan terbaik; bentuk lesi saja lemah (0,68). Pada retak jalan,

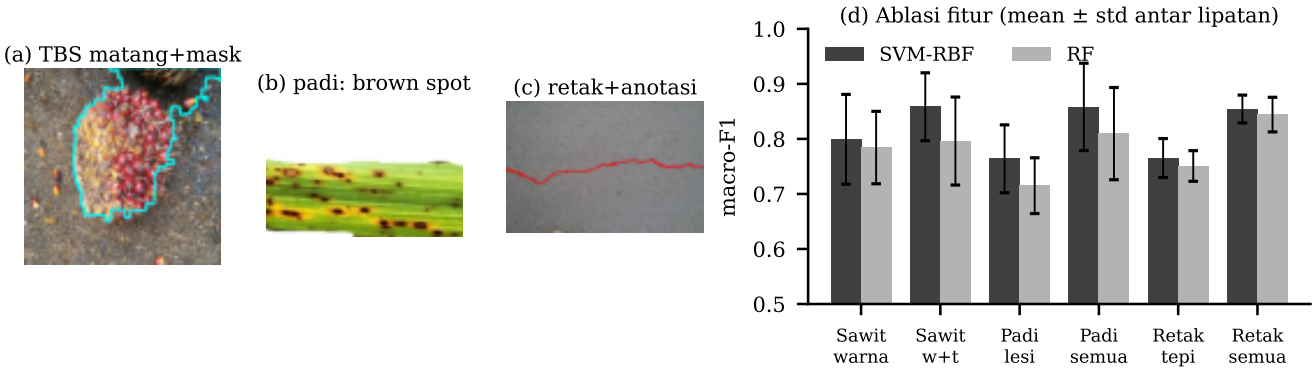


Fig. 1. (a)–(c) Contoh citra tiap kasus: TBS dengan kontur mask, daun padi brown spot, dan retak jalan dengan anotasi (merah). (d) Macro-F1 pada ablasi fitur; batang galat adalah simpangan baku antar lipatan.

TABLE I
Macro-F1 (rata-rata ± simpangan baku, 15 lipatan). Cetak tebal: terbaik per kasus.

Kasus	Fitur	SVM RBF	RF
Sawit	Warna, tanpa mask	$0{,}804 \pm 0{,}063$	$0{,}753 \pm 0{,}088$
	Warna, mask	$0{,}799 \pm 0{,}082$	$0{,}784 \pm 0{,}066$
	Tekstur saja	$0{,}656 \pm 0{,}065$	$0{,}672 \pm 0{,}072$
	Warna + tekstur	$\mathbf{0{,}858} \pm 0{,}062$	$0{,}796 \pm 0{,}080$
Padi	Warna daun utuh	$0{,}824 \pm 0{,}098$	$0{,}780 \pm 0{,}107$
	Warna lesi	$0{,}764 \pm 0{,}062$	$0{,}715 \pm 0{,}051$
	Bentuk lesi	$0{,}680 \pm 0{,}090$	$0{,}694 \pm 0{,}103$
	Tekstur	$0{,}760 \pm 0{,}069$	$0{,}630 \pm 0{,}096$
	Lesi + bentuk	$0{,}814 \pm 0{,}053$	$0{,}762 \pm 0{,}091$
	Lesi + bentuk + tekstur	$\mathbf{0{,}858} \pm 0{,}079$	$0{,}810 \pm 0{,}084$
Retak	Tepi (Canny/Sobel)	$0{,}765 \pm 0{,}035$	$0{,}751 \pm 0{,}028$
	Tepi + ridge + morfologi	$\mathbf{0{,}868} \pm 0{,}022$	$0{,}840 \pm 0{,}026$
	Tekstur (GLCM + LBP)	$0{,}787 \pm 0{,}020$	$0{,}778 \pm 0{,}027$
	Semua	$0{,}854 \pm 0{,}025$	$0{,}844 \pm 0{,}031$

fitur tepi/ridge/morfologi (0,868) mengungguli tepi sederhana (0,765) dan tekstur (0,787); menambah tekstur ke semua fitur tidak memperbaiki hasil (0,854).

V. Pembahasan

Kebocoran. Pada retak jalan, patch dari citra yang sama sangat mirip. Pembagian acak per patch memberi macro-F1 0,867 (SVM) dan 0,849 (RF) untuk semua fitur, lebih tinggi daripada 0,854 dan 0,844 dengan pembagian per citra: selisih kecil, tetapi searah dengan kebocoran.

Batasan. (i) Dataset kecil: dengan simpangan baku 0,06–0,10, selisih sekitar 0,05 (mis. SVM vs. RF) tidak dapat disimpulkan. (ii) Pada padi, warna daun utuh (0,824) mengungguli warna lesi (0,764); ini bisa mencerminkan kondisi akuisisi, dan citra dari daun yang sama mungkin ada di lipatan latih dan uji karena tidak ada ID daun. (iii) Sawit tanpa ID kebun atau blok, sehingga validasi antar-kebun tidak dapat diuji. (iv) Segmentasi lesi dan mask memakai ambang heuristik tanpa validasi anotasi. (v) Patch retak hanya 30%, sehingga dipakai macro-F1. Hasil tidak sebanding langsung dengan makalah rujukan.

VI. Kesimpulan

Fitur klasik dengan SVM RBF atau Random Forest menghasilkan macro-F1 sekitar 0,86 pada ketiga kasus. Fitur yang cocok bergantung pada penyebab visual kelasnya: warna untuk kematangan sawit, kombinasi warna lesi, bentuk, dan tekstur untuk penyakit padi, serta tepi dan morfologi garis untuk retak jalan. Pada data sekecil ini perbedaan antar-pengklasifikasi tidak bermakna; pemisahan per citra dan scaler di dalam pipeline menjadi syarat evaluasi yang valid.

References

[1] R. C. Gonzalez and R. E. Woods, Digital Image Processing, 4th ed. New York, NY, USA: Pearson, 2018.
[2] N. Fadilah, J. Mohamad-Saleh, Z. Abdul Halim, H. Ibrahim, and S. S. Syed Ali, "Intelligent color vision system for ripeness classification of oil palm fresh fruit bunch," Sensors, vol. 12, no. 10, pp. 14179–14195, 2012.
[3] J. W. Lai, H. R. Ramli, L. I. Ismail, and W. Z. Wan Hasan, "Oil palm fresh fruit bunch ripeness detection methods: A systematic review," Agriculture, vol. 13, no. 1, p. 156, 2023.
[4] Z. Omar, A. P. P. Abdul Majeed, M. Rosbi, S. A. Ghazalli, and H. Selamat, "Outdoor oil palm fruit ripeness dataset," Data in Brief, vol. 55, art. 110667, Aug. 2024.
[5] M. Rosbi, Z. Omar, U. Khairuddin, A. P. P. A. Majeed, and S. A. R. S. A. Bakar, "Machine learning for automated oil palm fruit grading: The role of fuzzy C-means segmentation and textural features," Smart Agric. Technol., vol. 9, art. 100691, Dec. 2024.
[6] M. A. Azim, M. K. Islam, M. M. Rahman, and F. Jahan, "An effective feature extraction method for rice leaf disease classification," TELKOMNIKA, vol. 19, no. 2, p. 463, Apr. 2021.
[7] Y. Shi, L. Cui, Z. Qi, F. Meng, and Z. Chen, "Automatic road crack detection using random structured forests," IEEE Trans. Intell. Transp. Syst., vol. 17, no. 12, pp. 3434–3445, Dec. 2016.
[8] Q. Zou, Y. Cao, Q. Li, Q. Mao, and S. Wang, "CrackTree: Automatic crack detection from pavement images," Pattern Recognit. Lett., vol. 33, no. 3, pp. 227–238, Feb. 2012.
[9] R. M. Haralick, K. Shanmugam, and I. Dinstein, "Textural features for image classification," IEEE Trans. Syst., Man, Cybern., vol. SMC-3, no. 6, pp. 610–621, Nov. 1973.
[10] T. Ojala, M. Pietikäinen, and T. Mäenpää, "Multiresolution gray-scale and rotation invariant texture classification with local binary patterns," IEEE Trans. Pattern Anal. Mach. Intell., vol. 24, no. 7, pp. 971–987, Jul. 2002.
[11] D. M. Woebbecke, G. E. Meyer, K. Von Bargen, and D. A. Mortensen, "Color indices for weed identification under various soil, residue, and lighting conditions," Trans. ASAE, vol. 38, no. 1, pp. 259–269, 1995.
[12] A. Gijsenij, T. Gevers, and J. van de Weijer, "Computational color constancy: Survey and experiments," IEEE Trans. Image Process., vol. 20, no. 9, pp. 2475–2489, Sep. 2011.